Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №4

По дисциплине: «Интервальный анализ»

Тема: «Интервальные описательные статистики и коэффициент Жаккара для оценивания параметров моделей»

Вариант № 8

Выполнила студент: Киселева Ксения

учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург

2026

Оглавление

1. Постановка задачи 3
2. Теоретическая часть 3
3. Реализация 6
4. Результаты 7
5. Обсуждение 9
6. Выводы 11

1. Постановка задачи

Цель работы: Получить практические навыки вычисления интервальных описательных статистик (моды, медиан), работы с коэффициентом Жаккара и применения методов оптимизации для интервальных данных. Сравнить эффективность различных функционалов на основе интервальных статистик для оценивания параметров моделей.

Задачи:
Даны два входных файла данных диагностики томсоновского рассеяния. (Формат входных данных описан в документе Save to BIN.pdf):

- -0.205_lvl_side_a_fast_data.bin
- 0.225_lvl_side_a_fast_data.bin

Связь кодов данных и Вольт для преобразования единиц измерения задается формулой: $V = \frac{Code}{16384} - 0.5$.

По данным из входных файлов необходимо реализовать следующее:

I. Извлечь интервальные выборки $X = \{x_i\}$ и $Y = \{y_i\}$ из бинарных файлов данных диагностики, задав радиусы элементов:
$$rad\ x = rad\ y = \frac{1}{2^N}, N = 14.$$
II. Пусть в зависимость Y от X задаётся следующими выражениями:
$$a + X = Y, t \cdot X = Y.$$
Вычислить точечные и интервальные оценки констант a и t с помощью некоторого функционала F, задавшись уровнем точности ε:
$$\hat{s} = \arg\max_s F(s, X, Y), s \in \{a, t\}.$$
Для функционала F рассмотреть следующие случаи:
   - B.1 На основе исходных выборок: $F(s, X, Y) = Ji(s, X, Y)$
   - B.2 На основе интервальных мод: $F(s, X, Y) = Ji(s, mode\ X, mode\ Y)$
   - B.3 На основе медиан Крейновича: $F(s, X, Y) = Ji(s, med_K X, med_K Y)$
   - B.4 На основе медиан Пролубникова: $F(s, X, Y) = Ji(s, med_P X, med_P Y)$

   где Ji - коэффициент Жаккара, mode - интервальная мода, med_K, med_P - интервальные медианы Крейновича и Пролубникова.
III. Для каждого пункта B.1-B.4 предоставить графики F(s), отметить s_{max}.
IV. Сравнить полученные результаты

2. Теоретическая часть

2.1 Интервальные данные и бинарный формат

В работе используются данные с диагностической установки (томсоновское рассеяние). Каждый файл имеет строго определенную структуру: 256 байт заголовка, а затем кадры по 16400 байт. Данные АЦП (коды) переводятся в физические величины (Вольты) по формуле:

$$V = \frac{Code}{16384} - 0.5$$

Так как измерения имеют погрешность, каждое полученное значение V мы представляем в виде интервала. Задается это значение V как середина интервала, а радиус интервала равен:

$$rad\ x = rad\ y = \frac{1}{2^N}, N = 14.$$

Тогда интервальный элемент выборки имеет вид $x_i = [V_i - rad, V_i + rad]$.

2.2 Коэффициент Жаккара для интервалов

Коэффициент Жаккара Ji - это мера сходства двух интервалов. Он показывает, насколько сильно они перекрываются. Определяется как отношение ширины их пересечения к ширине их объединения:

$$Ji(A, B) = \frac{wid(A \wedge B)}{wid(A \vee B)},$$

где $A \wedge B = [\max(\underline{A}, \underline{B}), \min(\overline{A}, \overline{B})]$ - пересечение, а $A \vee B = [\min(\underline{A}, \underline{B}), \max(\overline{A}, \overline{B})]$- оболочка (объединение).

Если интервалы не пересекаются, ширина пересечения считается отрицательной, поэтому коэффициент Жаккара может принимать значения от -1 до 1. Значение $Ji = 1$ означает полное совпадение интервалов, $Ji = 0$ - касание границ, $Ji < 0$ - отсутствие совместности.

Для интервальной выборки (множества интервалов X) коэффициент Жаккара вычисляется через общую область совместности всех её элементов:

$$Ji(x) = \frac{min_i \overline{x_i} - max_i \underline{x_i}}{max_i \overline{x_i} - min_i \underline{x_i}}.$$

Так как исходные выборки содержат большое число элементов, для вычисления функционала удобнее использовать глобальный коэффициент Жаккара через оболочки выборок.

Оболочка выборки X - интервал от минимума для максимума всех её элементов:

$$hull\ X = \left[min_i \underline{x_i}, max_i \overline{x_i}\right].$$

Тогда функционал для моделей вычисляется как коэффициент Жаккара между преобразованной оболочкой X и оболочкой Y:

$$F(s) = Ji(s \circ hull\ X, hull\ Y),$$

где $s \circ hull\ X$ - означает применение сдвига (для a) или масштабирования (для t). Такой подход позволяет быстро оценить совместимость выборок, используя только их крайние значения.

2.3 Интервальная мода

Интервальная мода $modeX$ - это такой интервал (набор интервалов), который покрывается наибольшим числом интервалов из выборки X, то есть самое «густое» место в выборке.

Чтобы найти моду, мы находим все точки (концы интервалов), считаем, сколько интервалов покрывают каждый участок, и выбираем участок с максимальным покрытием. Если таких участков несколько, мода может состоять из нескольких кусков (быть многосвязной).

Формально, если упорядочить все концы интервалов $E = \{\underline{x_1}, \overline{x_1}, \dots, \underline{x_n}, \overline{x_n}\}$ и рассмотреть функцию покрытия $\chi(t)$, равную числу интервалов, накрывающих точку t, то мода определяется как множество:

$$mode\ X = \{t \in \mathbb{R} \mid \chi(t) = \max_{\tau} \chi(\tau)\}.$$

2.4 Медианы Крейновича и Пролубникова

Для интервальных выборок существуют разные способы определить медиану. В работе используются две:
Медиана Крейновича med_K - это интервал, границы которого являются медианами нижних и верхних границ исходных интервалов:

$$med_K X = [med(\underline{x_i}), med(\overline{x_i})].$$

Медиана Пролубникова med_P - это более сложная конструкция, основанная на упорядочивании интервалов по их серединам. Если в выборке n элементов, то интервалы сортируются по возрастанию их середин $midx_i = \frac{(\underline{x_i}+\overline{x_i})}{2}$:

- При нечетном n медиана Пролубникова - это просто центральный интервал в упорядоченном по серединам ряду.

- При четном n - это интервал, построенный по двум центральным интервалам $x_{(k)}$ и $x_{(k+1)}$ (где $k = n/2$). В базовом варианте (медиана типа a) она определяется как их покомпонентное среднее:

$$med_P X = \left[\frac{\underline{x_{(k)}} + \underline{x_{(k+1)}}}{2}, \frac{\overline{x_{(k)}} + \overline{x_{(k+1)}}}{2}\right]$$

В литературе также рассматриваются варианты b (пересечение центральных интервалов) и c (их минимальная оболочка). В данной работе используется базовый вариант a, так как он всегда определен (в отличие от варианта b, где пересечение может быть пустым) и не дает завышенной оценки ширины медианы (в отличие от варианта c, где оболочка может быть слишком широкой).

В данной работе, так как все интервалы имеют одинаковый радиус, медианы Крейновича и Пролубникова часто совпадают.

2.5 Модели и функционал

Мы рассматриваем две модели зависимости Y от X:

1) Модель сдвига: $a + X = Y$. Параметр a (сдвиг) подбирается так, чтобы преобразованная выборка $a + X$ наилучшим образом совпадала с Y.
2) Модель масштабирования: $t \cdot X = Y$. Параметр t (коэффициент растяжения) подбирается аналогично.

Для поиска параметров $s \in \{a, t\}$ мы максимизируем функционал $F(s, X, Y)$. Рассмотриваются четыре варинта этого функционала:

B.1 На основе исходных выборок: $F(s, X, Y) = Ji(s, X, Y)$
B.2 На основе интервальных мод: $F(s, X, Y) = Ji(s, mode\ X, mode\ Y)$
B.3 На основе медиан Крейновича: $F(s, X, Y) = Ji(s, med_K X, med_K Y)$
B.4 На основе медиан Пролубникова: $F(s, X, Y) = Ji(s, med_P X, med_P Y)$

Оценка параметра находится как точка максимума функционала:

$$\hat{s} = \arg\max_s F(s, X, Y)$$

3. Реализация

Язык программирования: Python 3.14
Среда разработки: Jupyter Notebook
Библиотеки: numpy, matplotlib.pyplot, pathlib/numpy.fromfile.

Краткое описание методов:

- process_file(filepath) - принимает путь к бинарному файлу формата Save to BIN.pdf; читает заголовок и кадры данных, извлекает коды АЦП из всех 8 каналов; переводит коды в Вольты по заданной формуле; возвращает массив значений (819200 точек).
- calc_mode(mid, rad) - принимает массивы середин и радиусов; находит интервальную моду через подсчёт числа покрытий на каждом элементарном участке; возвращает середину и радиус моды.
- calc_med_K(mid, rad) - принимает массивы середин и радиусов; возвращает медиану Крейновича как интервал, границы которого - медианы нижних и верхних границ элементов выборки.
- calc_med_P(mid, rad) - принимает массивы середин и радиусов; возвращает медиану Пролубникова как медиану середин и медиану радиусов.
- calc_F_fast(s, minX, maxX, radX, minY, maxY, radY, model) - принимает значение параметра s, границы и радиус оболочек выборок X и Y, а также тип модели ('a' или 't'); вычисляет коэффициент Жаккара для оболочек без создания полных массивов (используя только минимумы и максимумы); возвращает значение $F(s) \in [-1,1]$.
- calc_grid(...) - принимает границы выборок; строит сетку значений параметра s (для a - в диапазоне разности оболочек, для t - в диапазоне отношений); возвращает массив значений s.
- calc_estimates(s, F) - принимает сетку s и значения F; находит точку максимума, множество $ArgmaxF$ и интервалы, где $F(s) \geq 0$.

Алгоритм:

Программа читает бинарные файлы, переводит коды АЦП в Вольты. Для каждой выборки вычисляются интервальная мода, медиана Крейновича и медиана Пролубникова. Затем для каждой модели и каждого варианта функционала (B.1–B.4) строится сетка значений s. Для каждого s вычисляется функционал F(s) как коэффициент Жаккара между оболочками преобразованной выборки X и выборки Y. Для каждого случая находится точка максимума и строится график F(s). Результаты выводятся в таблицу.

1. Результаты

a. Представители выборок

Таблица 1: Интервальные моды и медианы выборок

Представитель	X	Y
Мода	[0.17156982, 0.17163086]	[−0.17150879, −0.17144775]
Медиана Крейновича	[0.17291260, 0.17303467]	[−0.17059326, −0.17047119]
Медиана Пролубникова	[0.17291260, 0.17303467]	[−0.17059326, −0.17047119]

Как видно из таблицы, медианы Крейновича и Пролубникова совпадают. Это объясняется тем, что все интервалы в выборках имеют одинаковый радиус.

b. Оценки параметров

В таблицах 2 и 3 представлены результаты вычисления точечных оценок $\hat{a}$ и $\hat{t}$, множества $ArgmaxF$, области $F \geq 0$ и максимального значения фнкционала для каждого случая.

Таблица 2: Оценки для модели a+X=Y

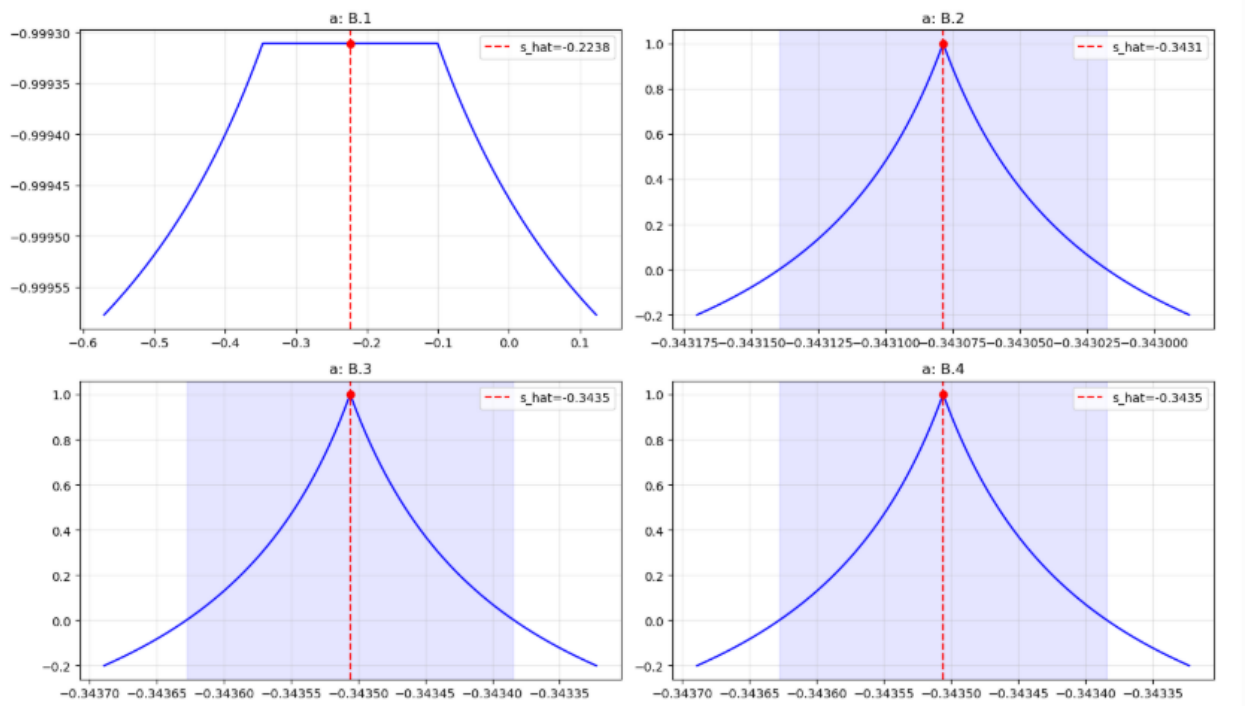
Функционал	$\hat{a}$	Диапазон, где $F \geq 0$	F_{max}
B.1, выборки	−0.223755	нет (пусто)	-0.999311
B.2, моды	−0.343079	[-0.343139, -0.343018]	1.000000
B.3, медианы K	−0.343506	[-0.343627, -0.343384]	1.000000
B.4, медианы P	−0.343506	[-0.343627, -0.343384]	1.000000

Таблица 3: Оценки для модели t*X=Y

Функционал	$\hat{t}$	$F \geq 0$	F_{max}
B.1, выборки	-0.113289	пусто	-0.999311
B.2, моды	-0.999289	[-0.999643, -0.998935]	0.999289
B.3, медианы K	-0.985890	[-0.986584, -0.985188]	0.985890
B.4, медианы P	-0.985890	[-0.986584, -0.985188]	0.985890

c. Графики функционалов

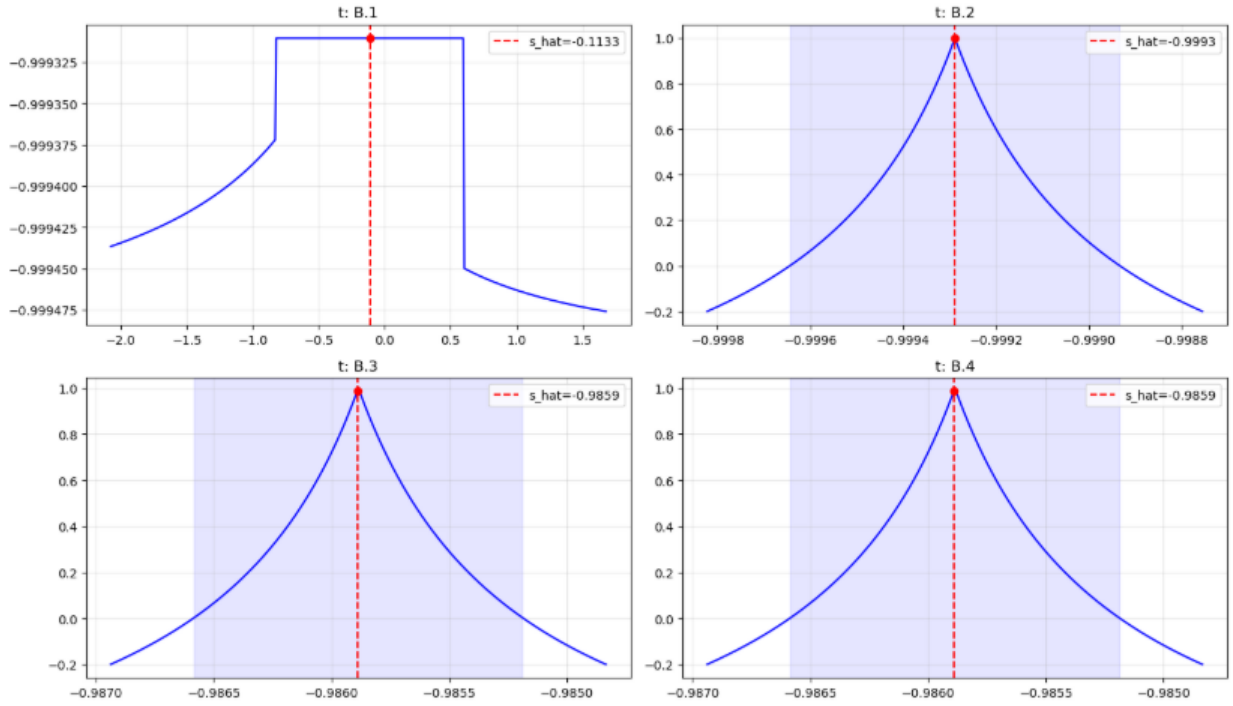
Рисунок 1: Функционал F(a) для модели a+X=Y



На графиках для модели a видно, что:

- B.1 (по выборкам) даёт широкое «плато», на котором функционал почти постоянен. Максимум −0.999311 отрицателен, поэтому множество $F \geq 0$ пусто.
- B.2–B.4 (по модам и медианам) дают острый пик с максимумом 1.0, достигаемым в одной точке. Для них существует узкий диапазон $F \geq 0$ (закрашен синим).

Рисунок 2: Функционал F(t) для модели t*X=Y



Для модели t картина аналогичная:

- B.1 даёт плато с максимумом −0.999311 и пустым множеством $F \geq 0$.
- B.2–B.4 дают острые пики с максимумами, близкими к 1.

5. Обсуждение

В ходе выполнения лабораторной работы мы исследовали два набора данных, полученных с диагностической установки. Эти данные мы представили в виде интервальных выборок, поскольку реальные измерения всегда содержат некоторую погрешность. Наша главная задача заключалась в том, чтобы понять, как связаны между собой две выборки X и Y, и подобрать такие параметры (сдвиг a или масштаб t), при которых эта связь проявляется наилучшим образом.

Для оценки качества подбора мы использовали коэффициент Жаккара - это числовая мера, которая показывает, насколько сильно два интервала перекрывают друг друга. Если перекрытие полное, коэффициент равен единице; если интервалы не пересекаются, он уходит в минус. Мы

рассмотрели четыре способа вычисления этого коэффициента: по исходным выборкам, по их модам (самым «густым» участкам) и по двум видам медиан (Крейновича и Пролубникова).

Сравнение результатов. Самое заметное различие в результатах возникло между первым случаем (B.1) и всеми остальными (B.2, B.3, B.4). Когда мы считали коэффициент Жаккара по всей выборке целиком, функционал вёл себя почти как константа. На графиках для B.1 видно широкое «плато»: максимальное значение функционала (около -0.999) достигается не в одной точке, а на большом отрезке. Это означает, что по исходным выборкам мы не можем получить надёжную оценку параметра: функция слишком «плоская» и не даёт чёткого максимума. Более того, во всех случаях B.1 значение F_{max} оказалось отрицательным, а значит, область $F \geq 0$ пуста - то есть при таком подходе мы вообще не находим совместных решений.

Совершенно иная картина наблюдается для мод и медиан (B.2-B.4). Как только мы заменяем громоздкие выборки их компактными представителями (модой или медианой), график функционала приобретает ярко выраженный острый пик. Максимум достигается ровно в одной точке, а его значение близко к единице. Это говорит о том, что при таком подходе мы находим чёткую и устойчивую оценку параметра. Например, для модели сдвига $a + X = Y$ оценка по моде составила около -0.343, а по медианам - около -0.3435. Для модели масштаба $t \cdot X = Y$ оценки оказались в районе -0.999 и -0.986 соответственно.

Влияние выбора представителя. Медианы Крейновича и Пролубникова дали абсолютно одинаковые результаты. Это не случайность: в наших данных все интервалы имеют одинаковый радиус (погрешность измерения одинакова для всех точек). Из-за этого медиана Пролубникова, которая строится по медианам середин и радиусов, совпадает с медианой Крейновича. Если бы радиусы были разными, результаты могли бы отличаться.

Также стоит отметить, что медианы дают чуть более «гладкую» и стабильную оценку, чем мода. Мода - это самый «частый» интервал, но она может быть чувствительна к случайным сгущениям точек. Медианы же опираются на середину упорядоченного ряда и меньше зависят от локальных особенностей выборки.

Практический вывод. Полученные результаты показывают, что для реальных интервальных данных использование точечных представителей (мод, медиан) оказывается гораздо эффективнее, чем работа с полными выборками. Когда мы имеем дело с сотнями тысяч точек, функционал «размывается» и теряет чувствительность. Замена выборки её компактным описанием (модой или медианой) позволяет сфокусироваться на главных особенностях распределения и получить чёткую оценку параметра. Это

особенно важно в задачах диагностики, где нужно быстро и надёжно определять характеристики сигнала.

6. Выводы

- Коэффициент Жаккара по исходным выборкам (B.1) не даёт устойчивой оценки: функционал почти постоянен, а область $F \geq 0$ пуста. Большие выборки «размывают» результат.
- Использование мод и медиан (B.2–B.4) даёт чёткую оценку: функционал имеет острый пик, максимум близок к 1, а оценки согласуются между собой (a=-0.343, t=-0.986 … -0.999).
- Медианы Крейновича и Пролубникова совпали, так как все интервалы имеют одинаковый радиус.
- Для практики лучше использовать компактные представители выборок (моды, медианы), а не полные наборы данных - это даёт надёжную оценку при меньших вычислительных затратах.

7. Приложение

Источник: Баженов А. Н. Интервальный анализ. Основы теории и учебные примеры. - СПб.: СПбПУ, 2020.

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

https://github.com/KiselevaKsu/IntervalAnalysis/tree/Lab4